Arquitetura/Ecossistema Hadoop que vamos utilizar neste treinamento

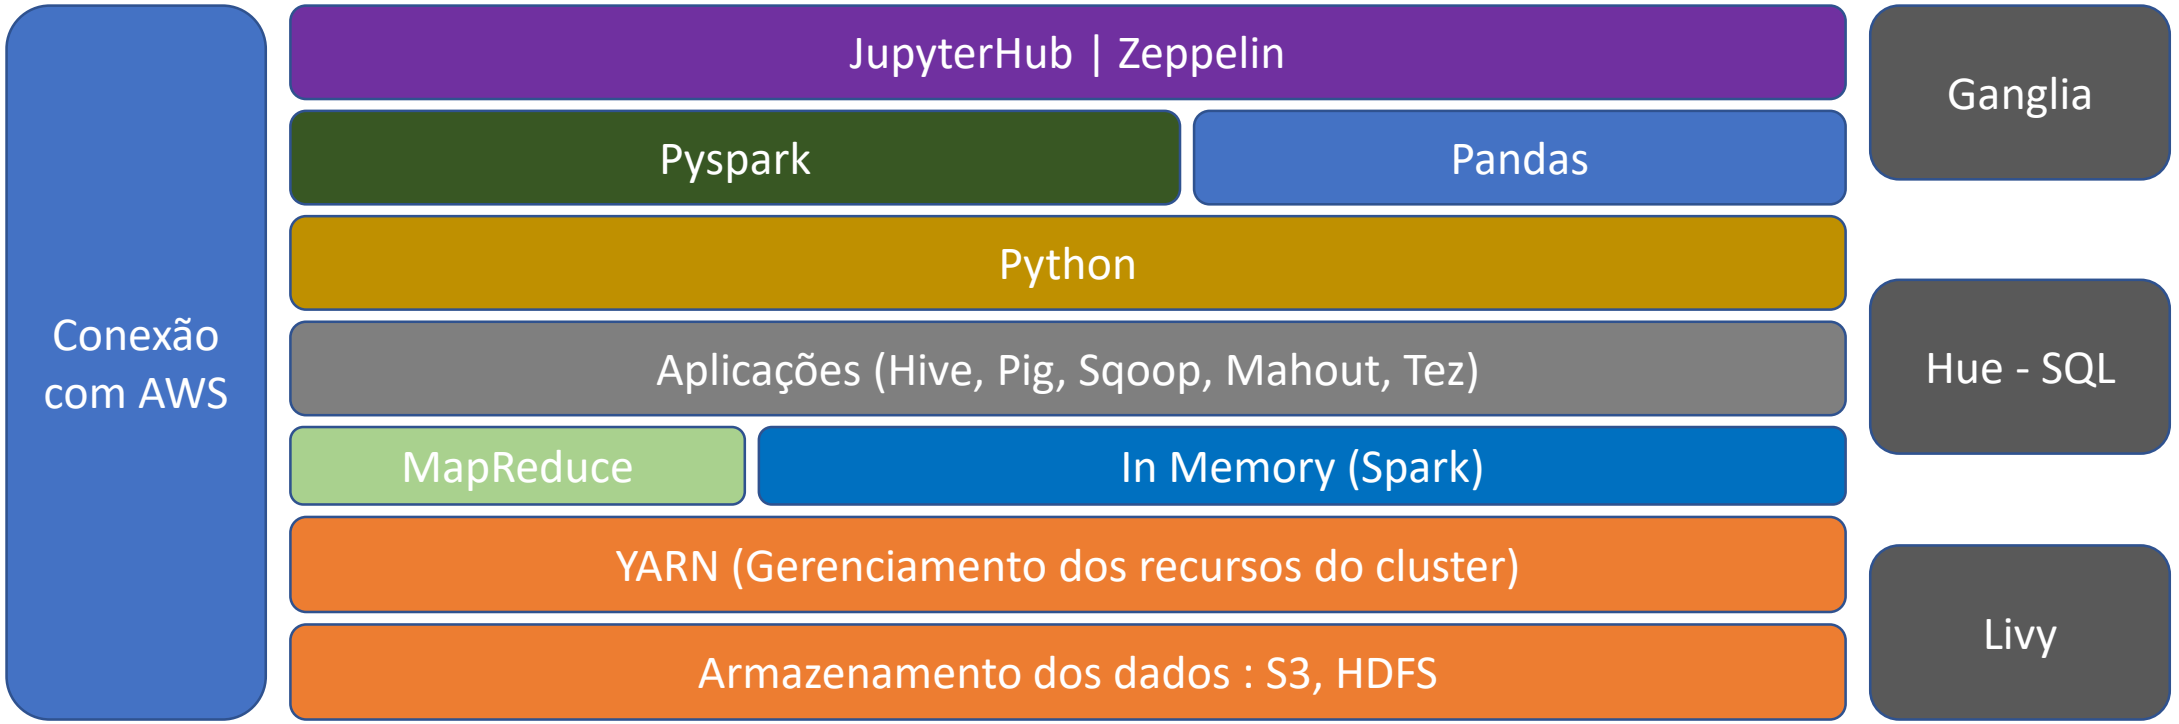

Arquivos necessários para treinamento

1) Clonar repositório para pasta local: acessar Git e copiar URL do repositório

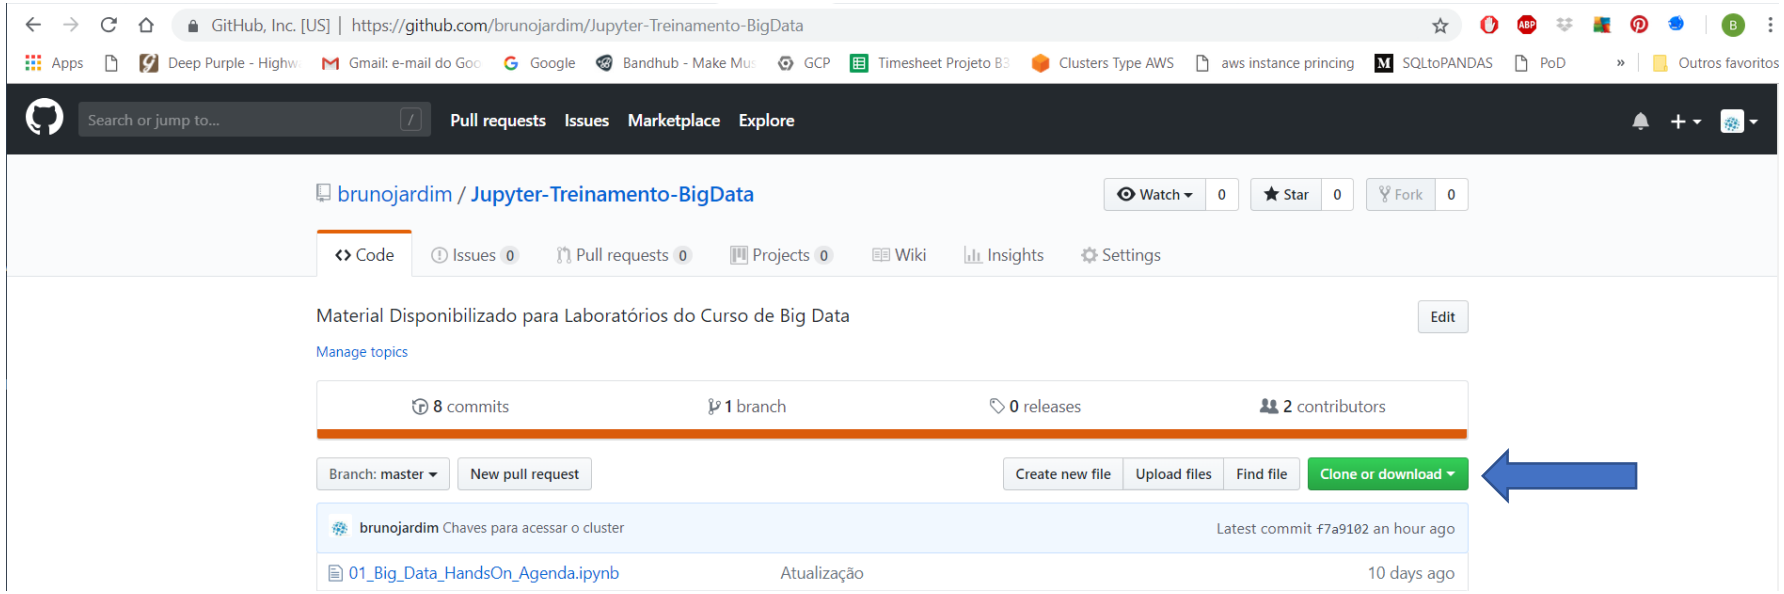

2) Acessar Git Bash (fazer download caso não tenha: https://git-scm.com/downloads)
3) Acesse uma pasta local do seu computador via Git Bash:
Cd <caminho/pasta/local>
Git clone <URL copiada do Git(site)>

treinamento_2018@bigdata

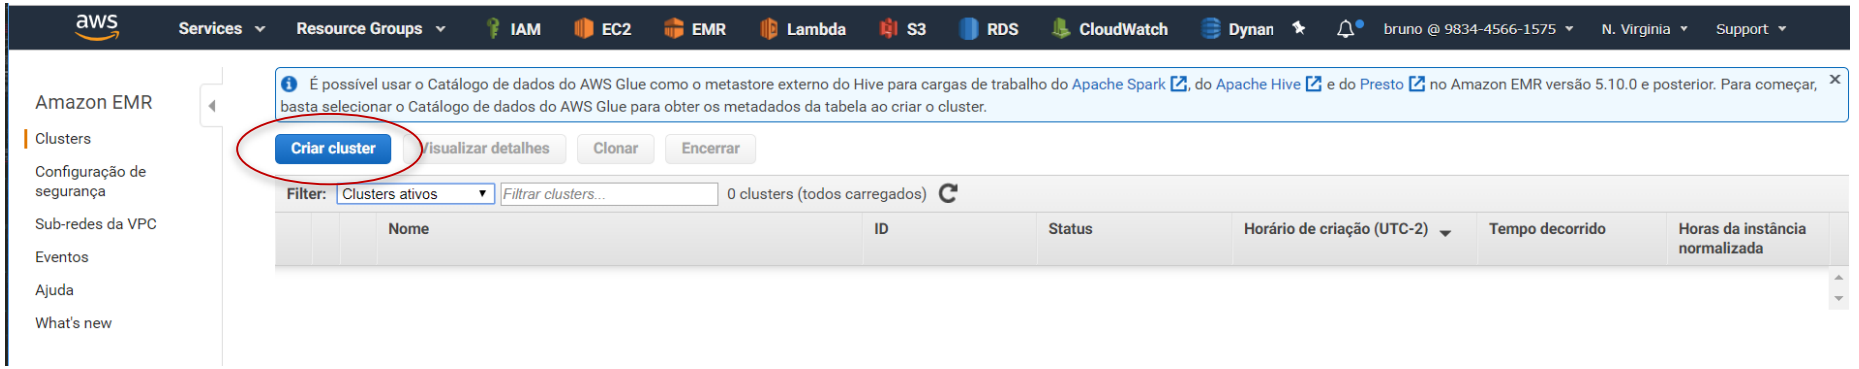
aws
Services
Resource Groups
IAM
EC2
EMR
Lambda
S3
RDS
CloudWatch
Dynan
bruno @ 9834-4566-1575
N. Virginia
Support
Amazon EMR
Clusters
Configuração de segurança
Sub-redes da VPC
Eventos
Ajuda
What's new
É possível usar o Catálogo de dados do AWS Glue como o metastore externo do Hive para cargas de trabalho do Apache Spark, do Apache Hive e do Presto no Amazon EMR versão 5.10.0 e posterior. Para começar, basta selecionar o Catálogo de dados do AWS Glue para obter os metadados da tabela ao criar o cluster.
Criar cluster
Visualizar detalhes
Clonar
Encerrar
Filter:
Clusters ativos
Filtrar clusters...
0 clusters (todos carregados)
Nome
ID
Status
Horário de criação (UTC-2)
Tempo decorrido
Horas da instância normalizada

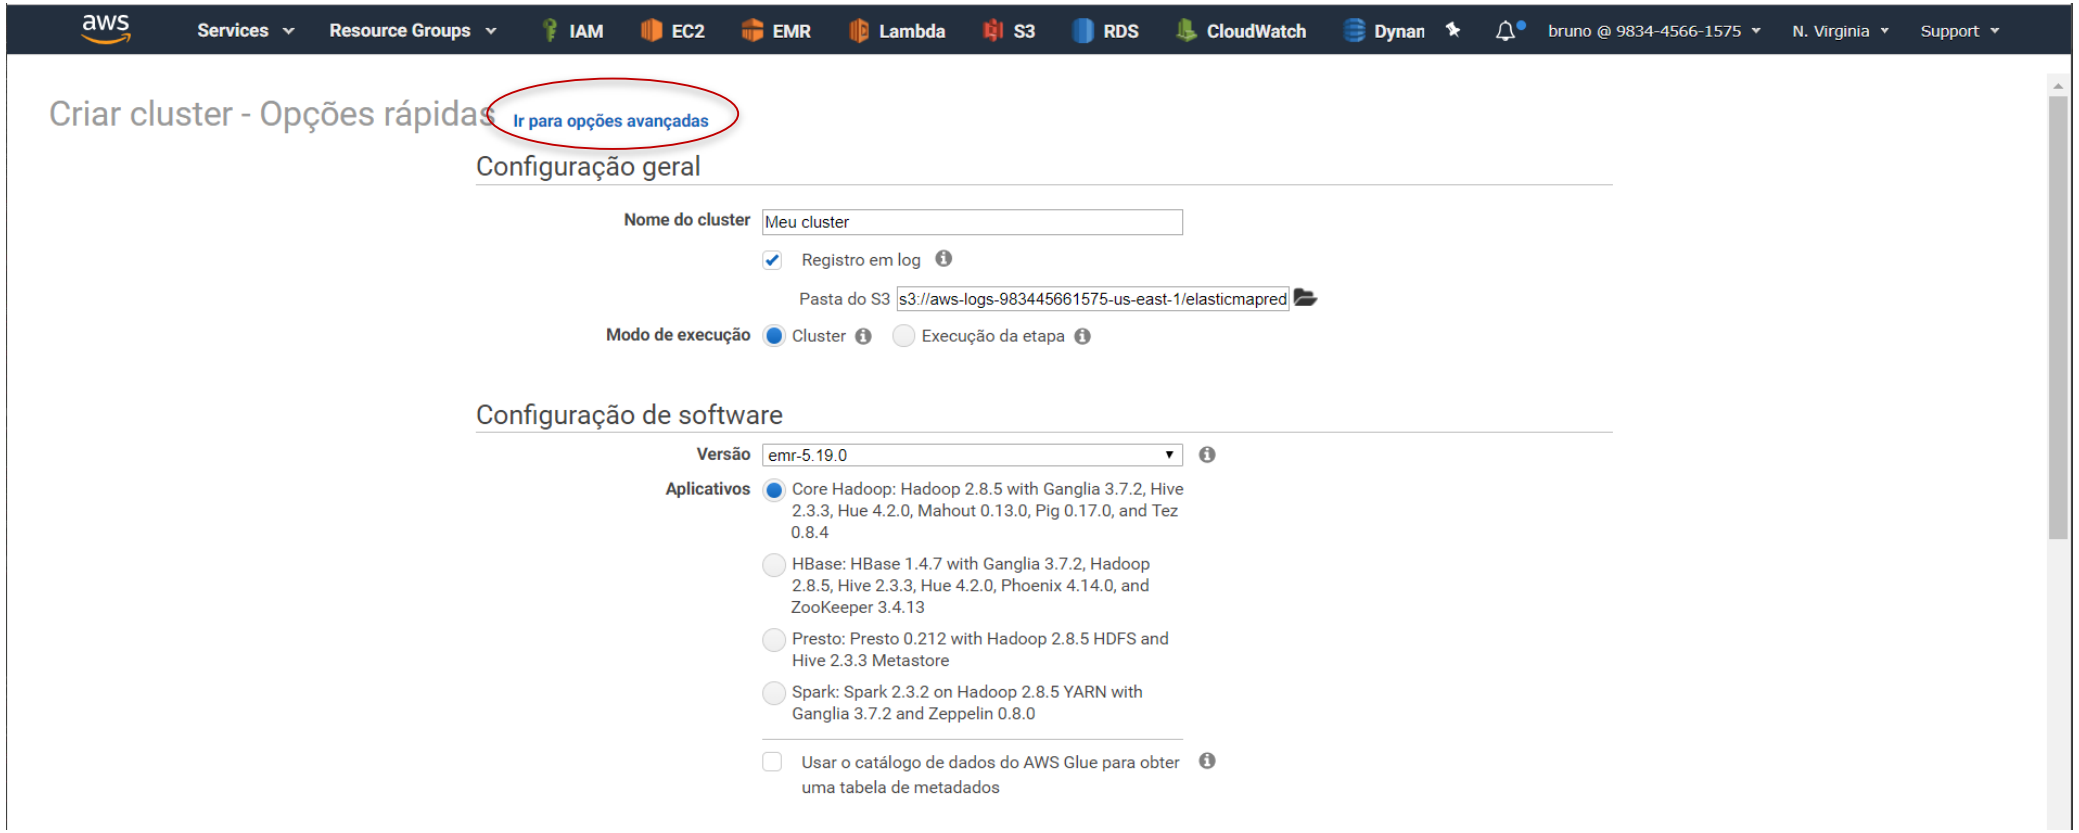
aws
Services
Resource Groups
IAM
EC2
EMR
Lambda
S3
RDS
CloudWatch
Dynan
bruno @ 9834-4566-1575
N. Virginia
Support
Criar cluster - Opções rápidas
Ir para opções avançadas
Configuração geral
Nome do cluster
Meu cluster
Registro em log
Pasta do S3
s3://aws-logs-983445661575-us-east-1/elasticmapred
Modo de execução
Cluster
Execução da etapa
Configuração de software
Versão
emr-5.19.0
Aplicativos
Core Hadoop: Hadoop 2.8.5 with Ganglia 3.7.2, Hive 2.3.3, Hue 4.2.0, Mahout 0.13.0, Pig 0.17.0, and Tez 0.8.4
HBase: HBase 1.4.7 with Ganglia 3.7.2, Hadoop 2.8.5, Hive 2.3.3, Hue 4.2.0, Phoenix 4.14.0, and ZooKeeper 3.4.13
Presto: Presto 0.212 with Hadoop 2.8.5 HDFS and Hive 2.3.3 Metastore
Spark: Spark 2.3.2 on Hadoop 2.8.5 YARN with Ganglia 3.7.2 and Zeppelin 0.8.0
Usar o catálogo de dados do AWS Glue para obter uma tabela de metadados

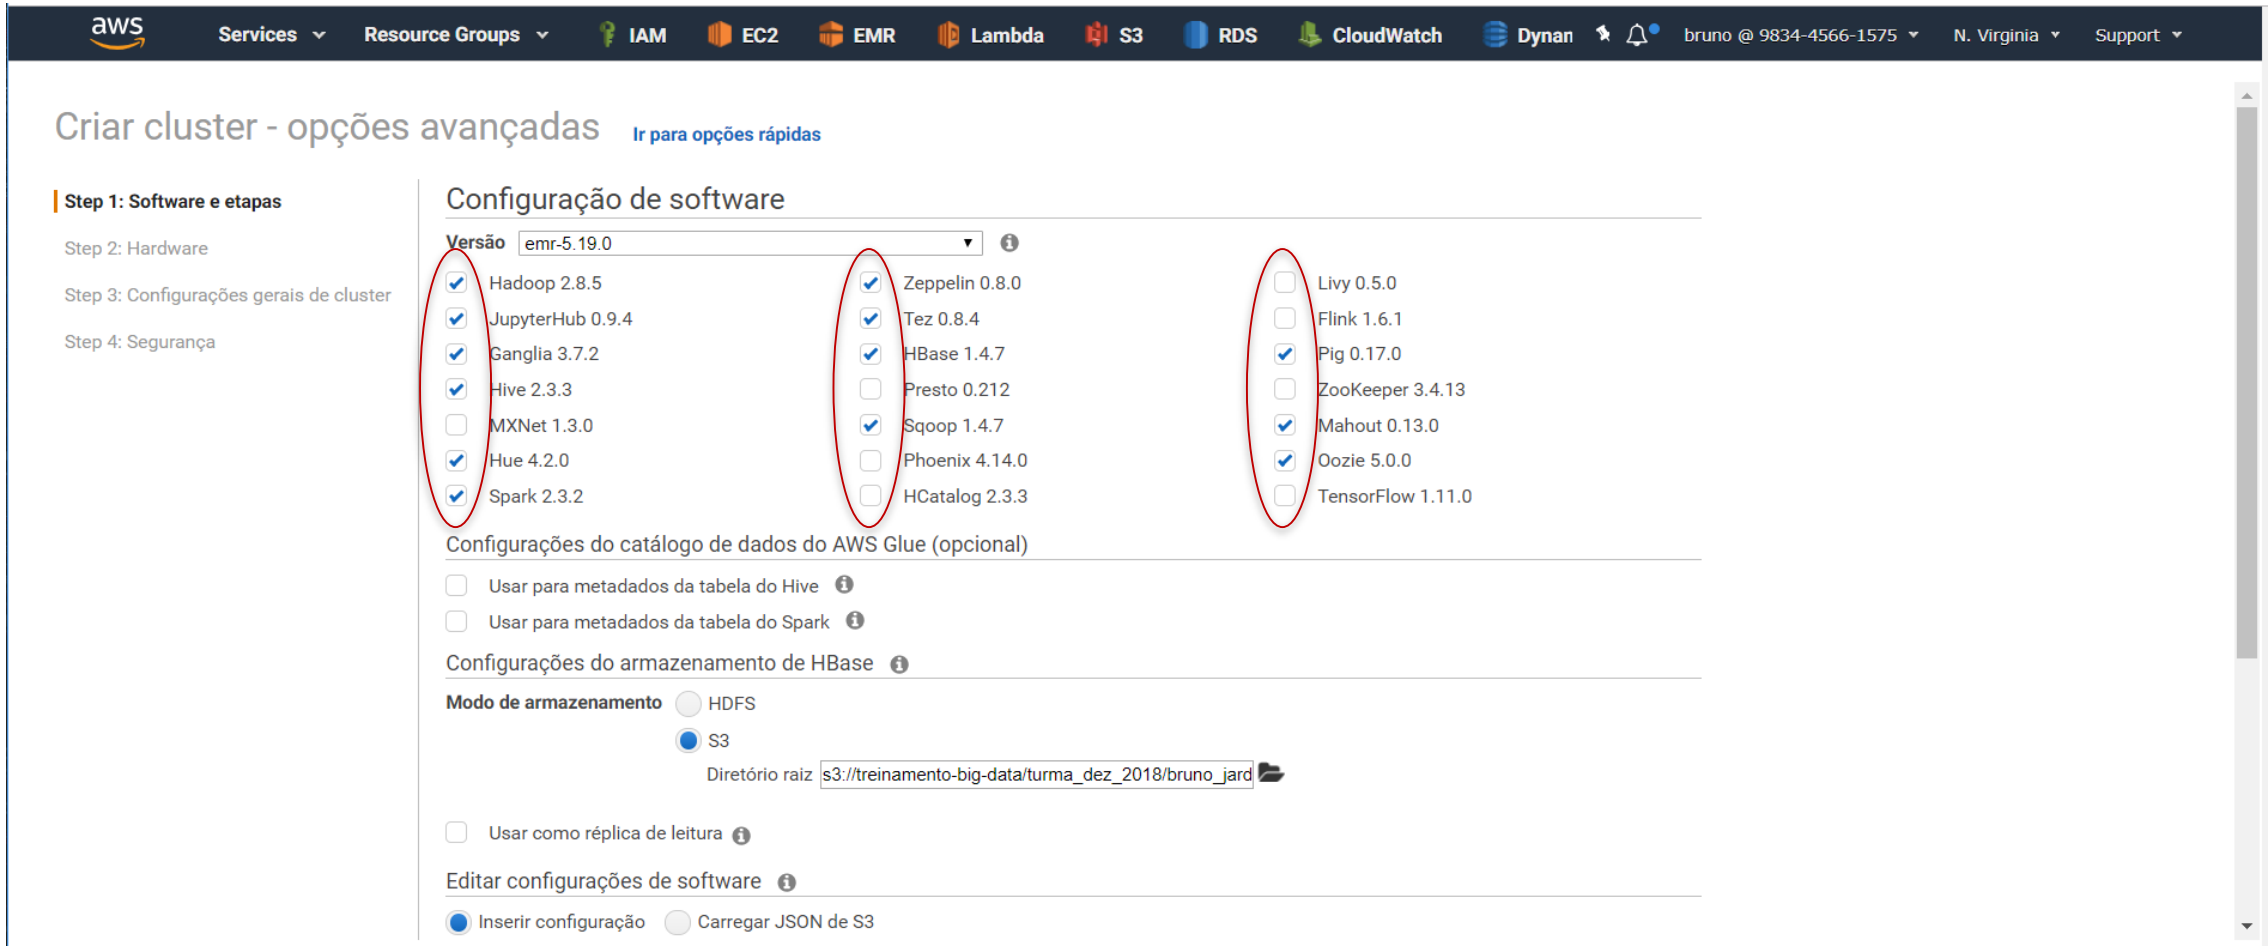
aws
Services
Resource Groups
IAM
EC2
EMR
Lambda
S3
RDS
CloudWatch
Dynan
bruno @ 9834-4566-1575
N. Virginia
Support
Criar cluster - opções avançadas
Ir para opções rápidas
Step 1: Software e etapas
Step 2: Hardware
Step 3: Configurações gerais de cluster
Step 4: Segurança
Configuração de software
Versão
emr-5.19.0
Hadoop 2.8.5
JupyterHub 0.9.4
Ganglia 3.7.2
Hive 2.3.3
MXNet 1.3.0
Hue 4.2.0
Spark 2.3.2
Zeppelin 0.8.0
Tez 0.8.4
HBase 1.4.7
Presto 0.212
Sqoop 1.4.7
Phoenix 4.14.0
HCatalog 2.3.3
Livy 0.5.0
Flink 1.6.1
Pig 0.17.0
ZooKeeper 3.4.13
Mahout 0.13.0
Oozie 5.0.0
TensorFlow 1.11.0
Configurações do catálogo de dados do AWS Glue (opcional)
Usar para metadados da tabela do Hive
Usar para metadados da tabela do Spark
Configurações do armazenamento de HBase
Modo de armazenamento
HDFS
S3
Diretório raiz
s3://treinamento-big-data/turma_dez_2018/bruno_jard
Usar como réplica de leitura
Editar configurações de software
Inserir configuração
Carregar JSON de S3

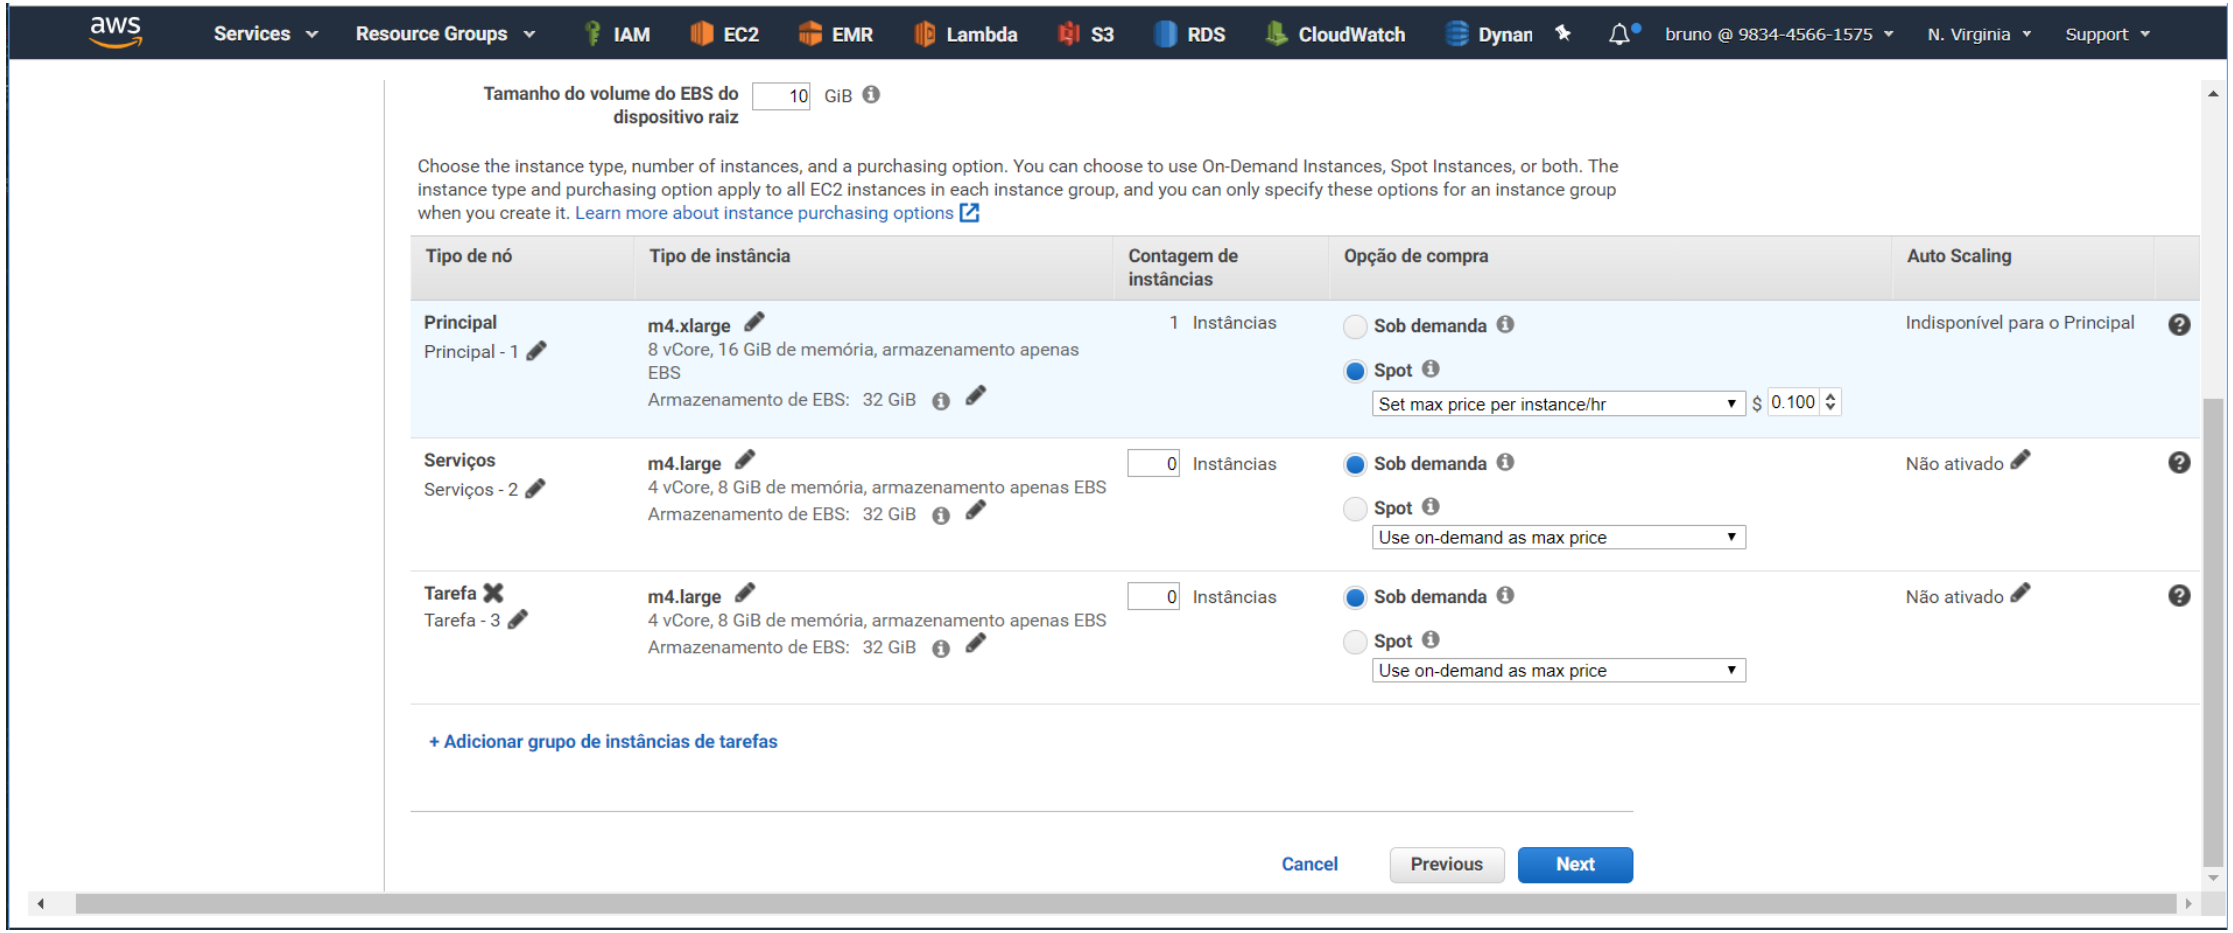
aws
Services
Resource Groups
IAM
EC2
EMR
Lambda
S3
RDS
CloudWatch
Dynan
bruno @ 9834-4566-1575
N. Virginia
Support
Tamanho do volume do EBS do dispositivo raiz
10
GiB
Choose the instance type, number of instances, and a purchasing option. You can choose to use On-Demand Instances, Spot Instances, or both. The instance type and purchasing option apply to all EC2 instances in each instance group, and you can only specify these options for an instance group when you create it. Learn more about instance purchasing options
Tipo de nó
Tipo de instância
Contagem de instâncias
Opção de compra
Auto Scaling
Principal
Principal - 1
m4.xlarge
8 vCore, 16 GiB de memória, armazenamento apenas EBS
Armazenamento de EBS: 32 GiB
1 Instâncias
Sob demanda
Spot
Set max price per instance/hr
$ 0.100
Indisponível para o Principal
Serviços
Serviços - 2
m4.large
4 vCore, 8 GiB de memória, armazenamento apenas EBS
Armazenamento de EBS: 32 GiB
0 Instâncias
Sob demanda
Spot
Use on-demand as max price
Não ativado
Tarefa
Tarefa - 3
m4.large
4 vCore, 8 GiB de memória, armazenamento apenas EBS
Armazenamento de EBS: 32 GiB
0 Instâncias
Sob demanda
Spot
Use on-demand as max price
Não ativado
+ Adicionar grupo de instâncias de tarefas
Cancel
Previous
Next

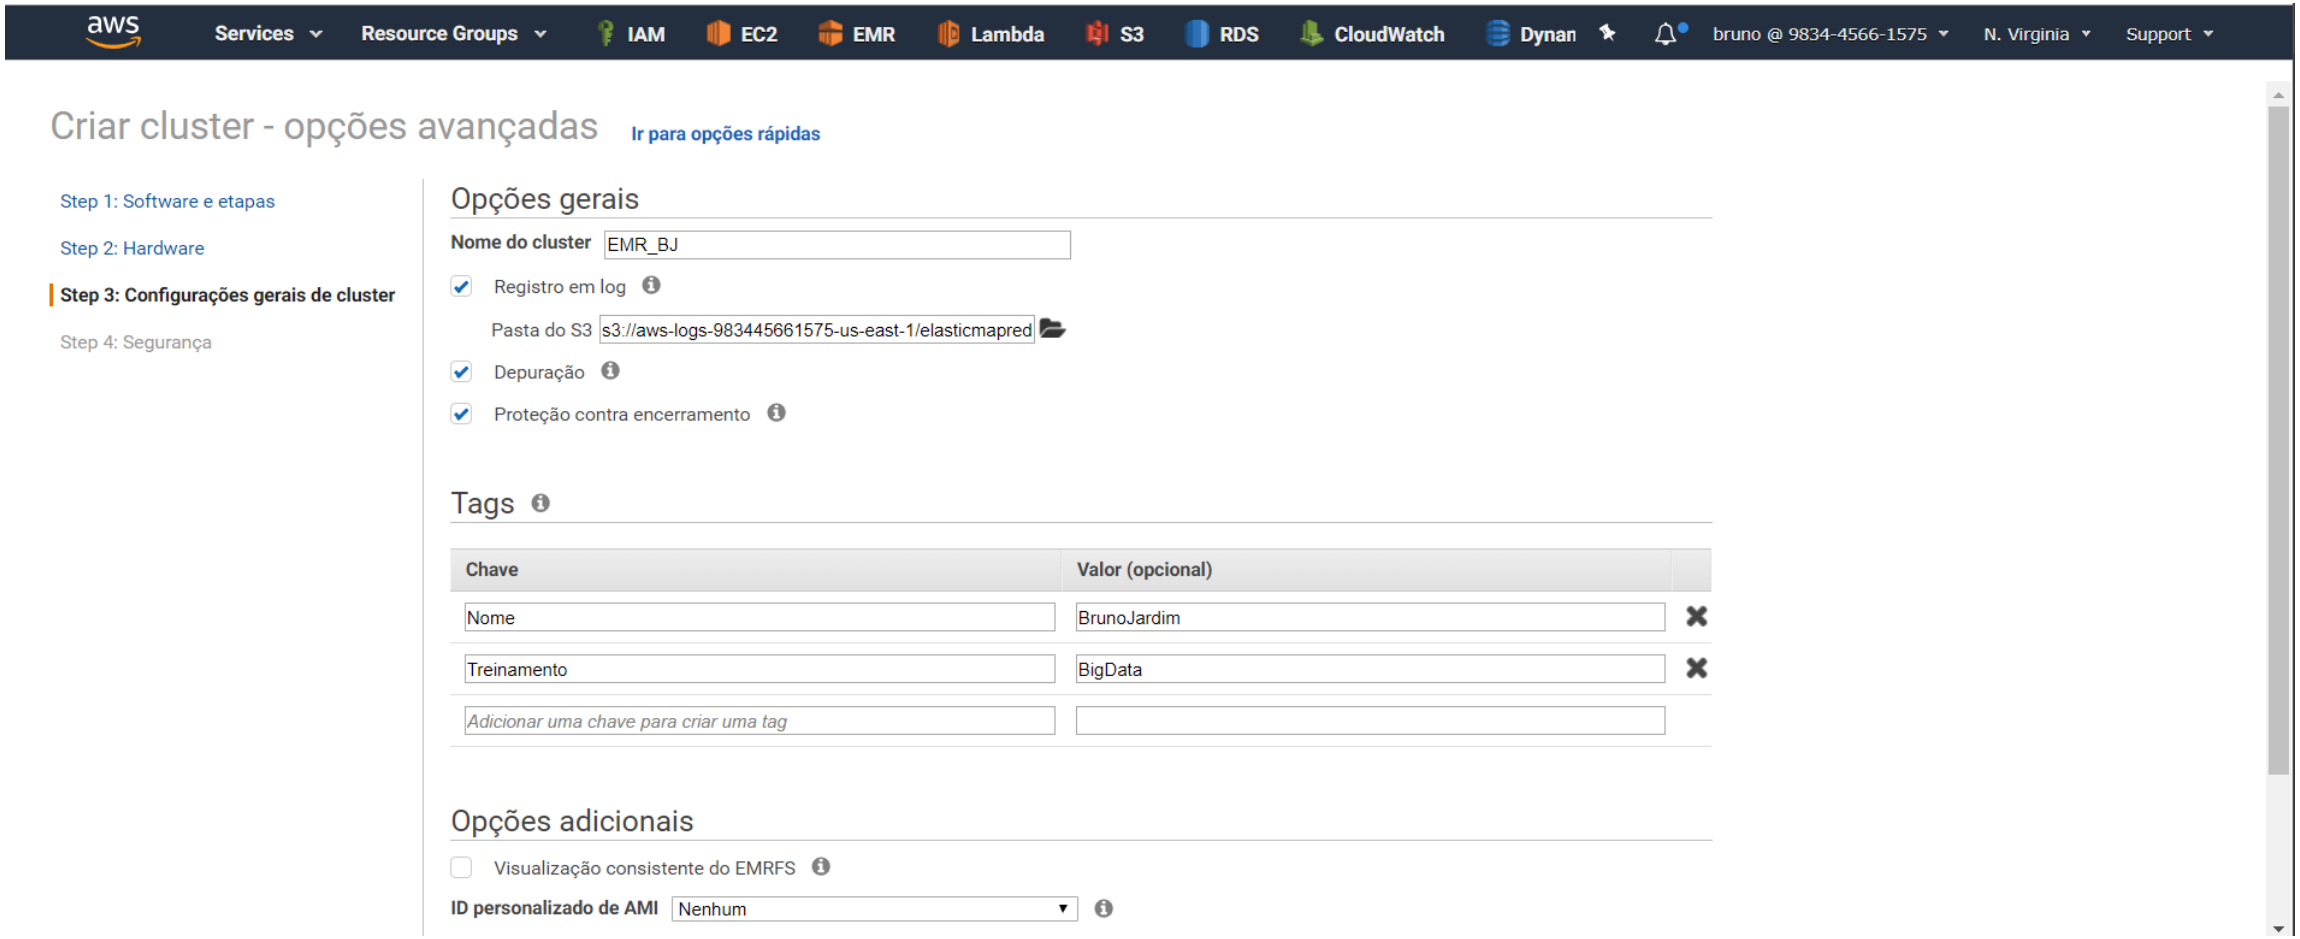
aws
Services
Resource Groups
IAM
EC2
EMR
Lambda
S3
RDS
CloudWatch
Dynan
bruno @ 9834-4566-1575
N. Virginia
Support
Criar cluster - opções avançadas
Ir para opções rápidas
Step 1: Software e etapas
Step 2: Hardware
Step 3: Configurações gerais de cluster
Step 4: Segurança
Opções gerais
Nome do cluster
EMR_BJ
Registro em log
Pasta do S3
s3://aws-logs-983445661575-us-east-1/elasticmapred
Depuração
Proteção contra encerramento
Tags
Chave
Valor (opcional)
Nome
BrunoJardim
Treinamento
BigData
Adicionar uma chave para criar uma tag
Opções adicionais
Visualização consistente do EMRFS
ID personalizado de AMI
Nenhum

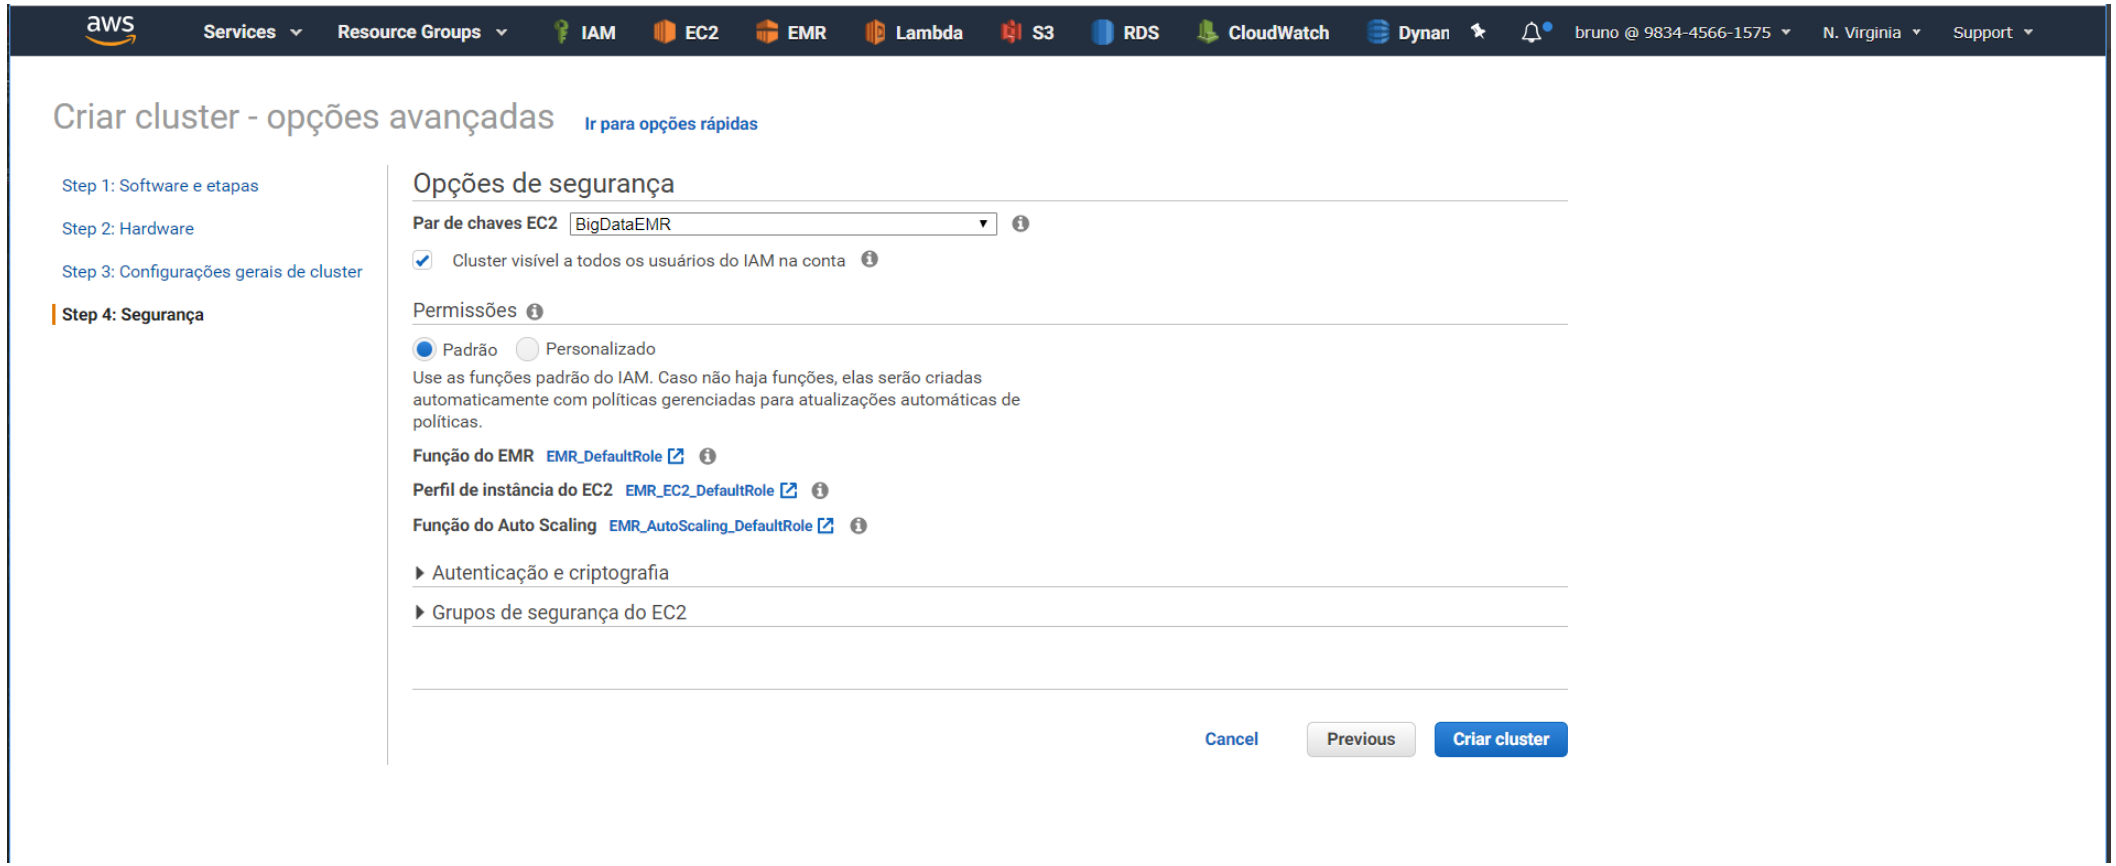
aws
Services
Resource Groups
IAM
EC2
EMR
Lambda
S3
RDS
CloudWatch
Dynan
bruno @ 9834-4566-1575
N. Virginia
Support
Criar cluster - opções avançadas
Ir para opções rápidas
Step 1: Software e etapas
Step 2: Hardware
Step 3: Configurações gerais de cluster
Step 4: Segurança
Opções de segurança
Par de chaves EC2
BigDataEMR
Cluster visível a todos os usuários do IAM na conta
Permissões
Padrão
Personalizado
Use as funções padrão do IAM. Caso não haja funções, elas serão criadas automaticamente com políticas gerenciadas para atualizações automáticas de políticas.
Função do EMR
EMR_DefaultRole
Perfil de instância do EC2
EMR_EC2_DefaultRole
Função do Auto Scaling
EMR_AutoScaling_DefaultRole
Autenticação e criptografia
Grupos de segurança do EC2
Cancel
Previous
Criar cluster

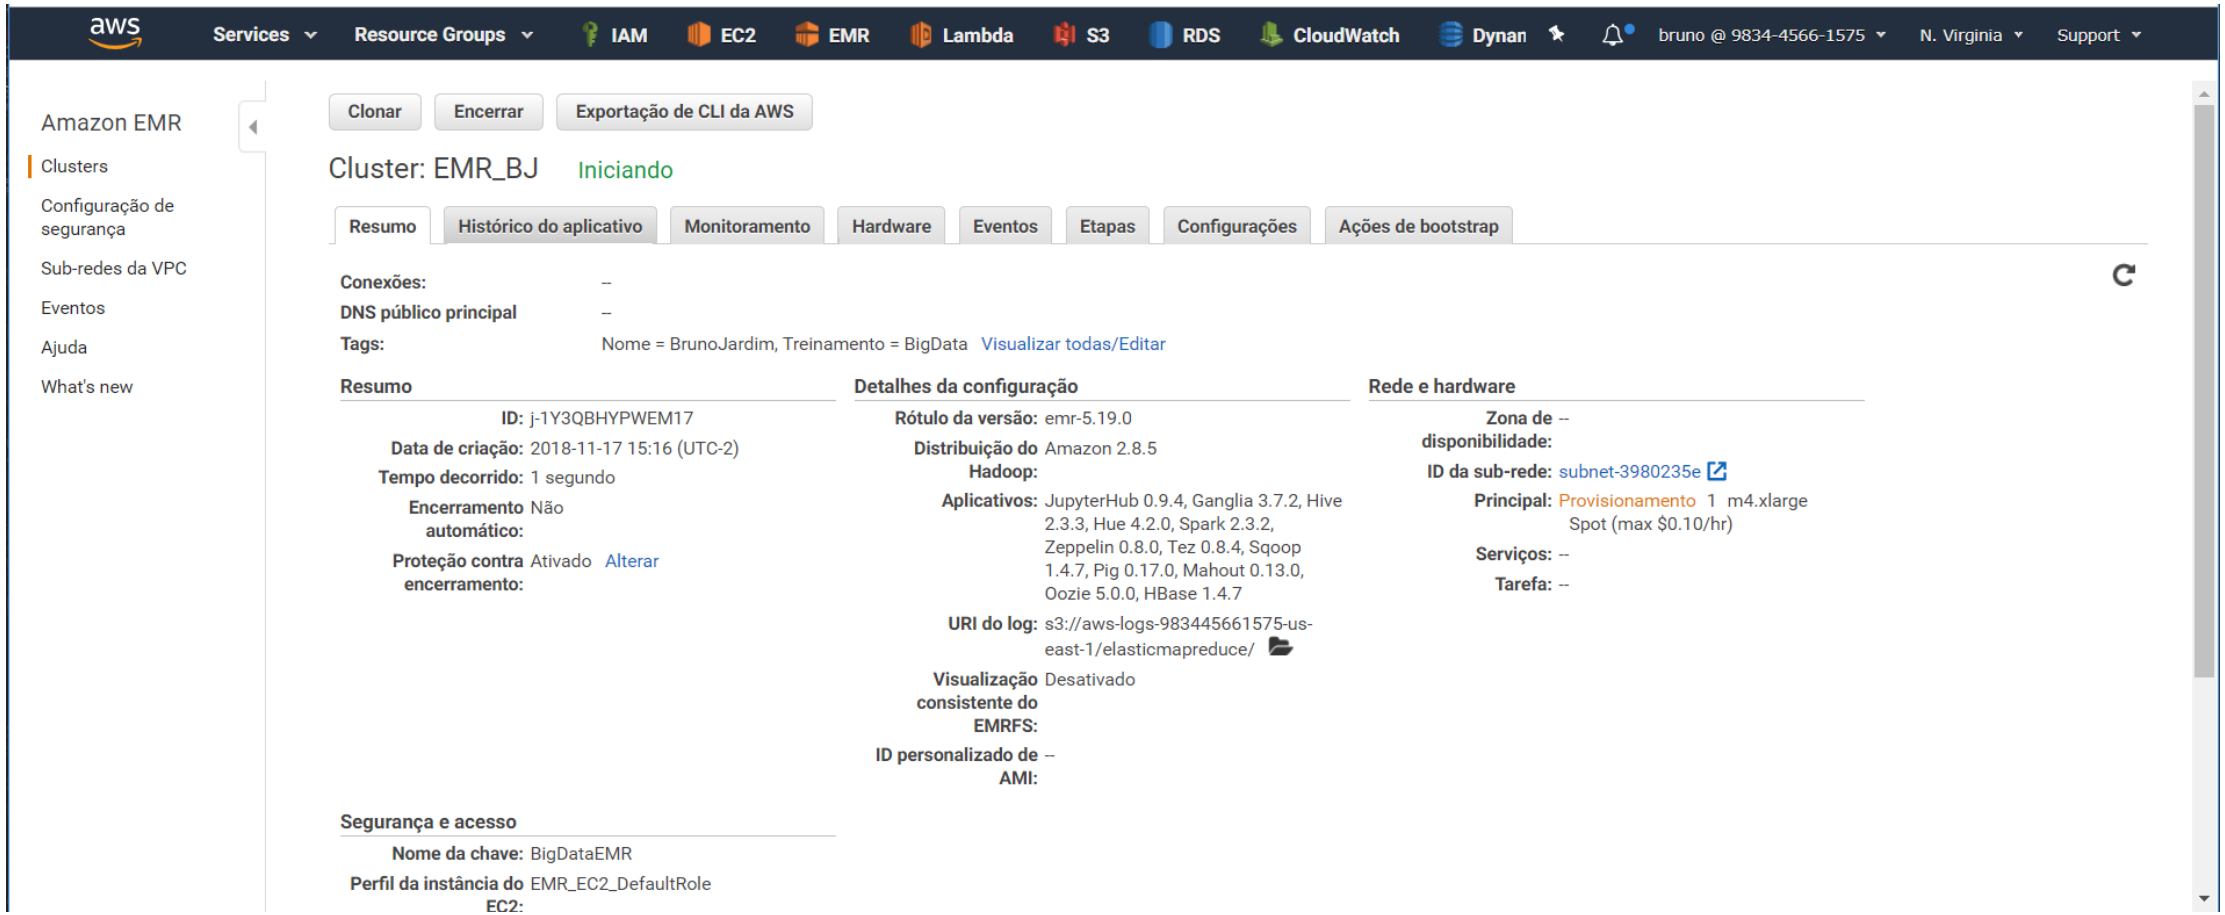
aws
Services
Resource Groups
IAM
EC2
EMR
Lambda
S3
RDS
CloudWatch
Dynan
bruno @ 9834-4566-1575
N. Virginia
Support
Amazon EMR
Clusters
Configuração de segurança
Sub-redes da VPC
Eventos
Ajuda
What's new
Clonar
Encerrar
Exportação de CLI da AWS
Cluster: EMR_BJ
Iniciando
Resumo
Histórico do aplicativo
Monitoramento
Hardware
Eventos
Etapas
Configurações
Ações de bootstrap
Conexões: --
DNS público principal --
Tags: Nome = BrunoJardim, Treinamento = BigData Visualizar todas/Editar
Resumo
ID: j-1Y3QBHYPWEM17
Data de criação: 2018-11-17 15:16 (UTC-2)
Tempo decorrido: 1 segundo
Encerramento automático: Não
Proteção contra encerramento: Ativado Alterar
Detalhes da configuração
Rótulo da versão: emr-5.19.0
Distribuição do Hadoop: Amazon 2.8.5
Aplicativos: JupyterHub 0.9.4, Ganglia 3.7.2, Hive 2.3.3, Hue 4.2.0, Spark 2.3.2, Zeppelin 0.8.0, Tez 0.8.4, Sqoop 1.4.7, Pig 0.17.0, Mahout 0.13.0, Oozie 5.0.0, HBase 1.4.7
URI do log: s3://aws-logs-983445661575-us-east-1/elasticmapreduce/
Visualização consistente do EMRFS: Desativado
ID personalizado de AMI: --
Rede e hardware
Zona de disponibilidade: --
ID da sub-rede: subnet-3980235e
Principal: Provisionamento 1 m4.xlarge Spot (max $0.10/hr)
Serviços: --
Tarefa: --
Segurança e acesso
Nome da chave: BigDataEMR
Perfil da instância do EC2: EMR_EC2_DefaultRole

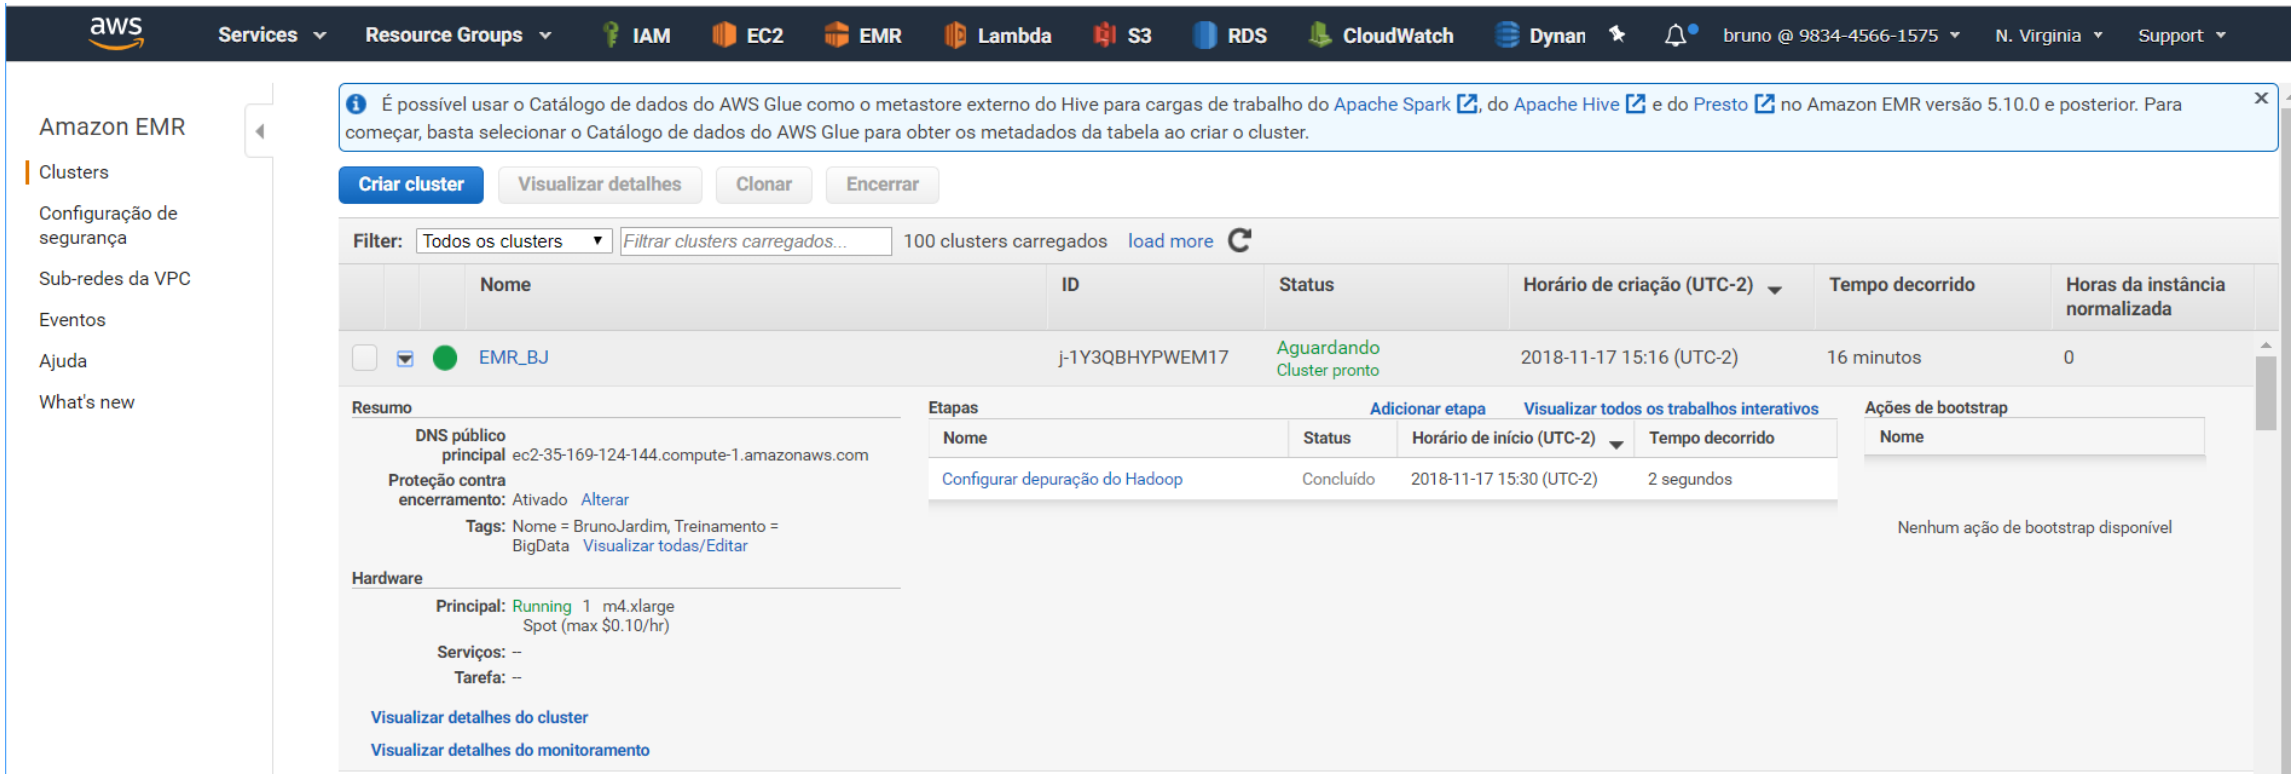
aws
Services
Resource Groups
IAM
EC2
EMR
Lambda
S3
RDS
CloudWatch
Dynan
bruno @ 9834-4566-1575
N. Virginia
Support
Amazon EMR
Clusters
Configuração de segurança
Sub-redes da VPC
Eventos
Ajuda
What's new
É possível usar o Catálogo de dados do AWS Glue como o metastore externo do Hive para cargas de trabalho do Apache Spark, do Apache Hive e do Presto no Amazon EMR versão 5.10.0 e posterior. Para começar, basta selecionar o Catálogo de dados do AWS Glue para obter os metadados da tabela ao criar o cluster.
Criar cluster
Visualizar detalhes
Clonar
Encerrar
Filter: Todos os clusters
Filtrar clusters carregados...
100 clusters carregados
load more
Nome
ID
Status
Horário de criação (UTC-2)
Tempo decorrido
Horas da instância normalizada
EMR_BJ
j-1Y3QBHYPWEM17
Aguardando
Cluster pronto
2018-11-17 15:16 (UTC-2)
16 minutos
0
Resumo
DNS público principal: ec2-35-169-124-144.compute-1.amazonaws.com
Proteção contra encerramento: Ativado Alterar
Tags: Nome = BrunoJardim, Treinamento = BigData Visualizar todas/Editar
Hardware
Principal: Running 1 m4.xlarge
Spot (max $0.10/hr)
Serviços: --
Tarefa: --
Visualizar detalhes do cluster
Visualizar detalhes do monitoramento
Etapas
Adicionar etapa
Visualizar todos os trabalhos interativos
Nome
Status
Horário de início (UTC-2)
Tempo decorrido
Configurar depuração do Hadoop
Concluído
2018-11-17 15:30 (UTC-2)
2 segundos
Ações de bootstrap
Nome
Nenhum ação de bootstrap disponível

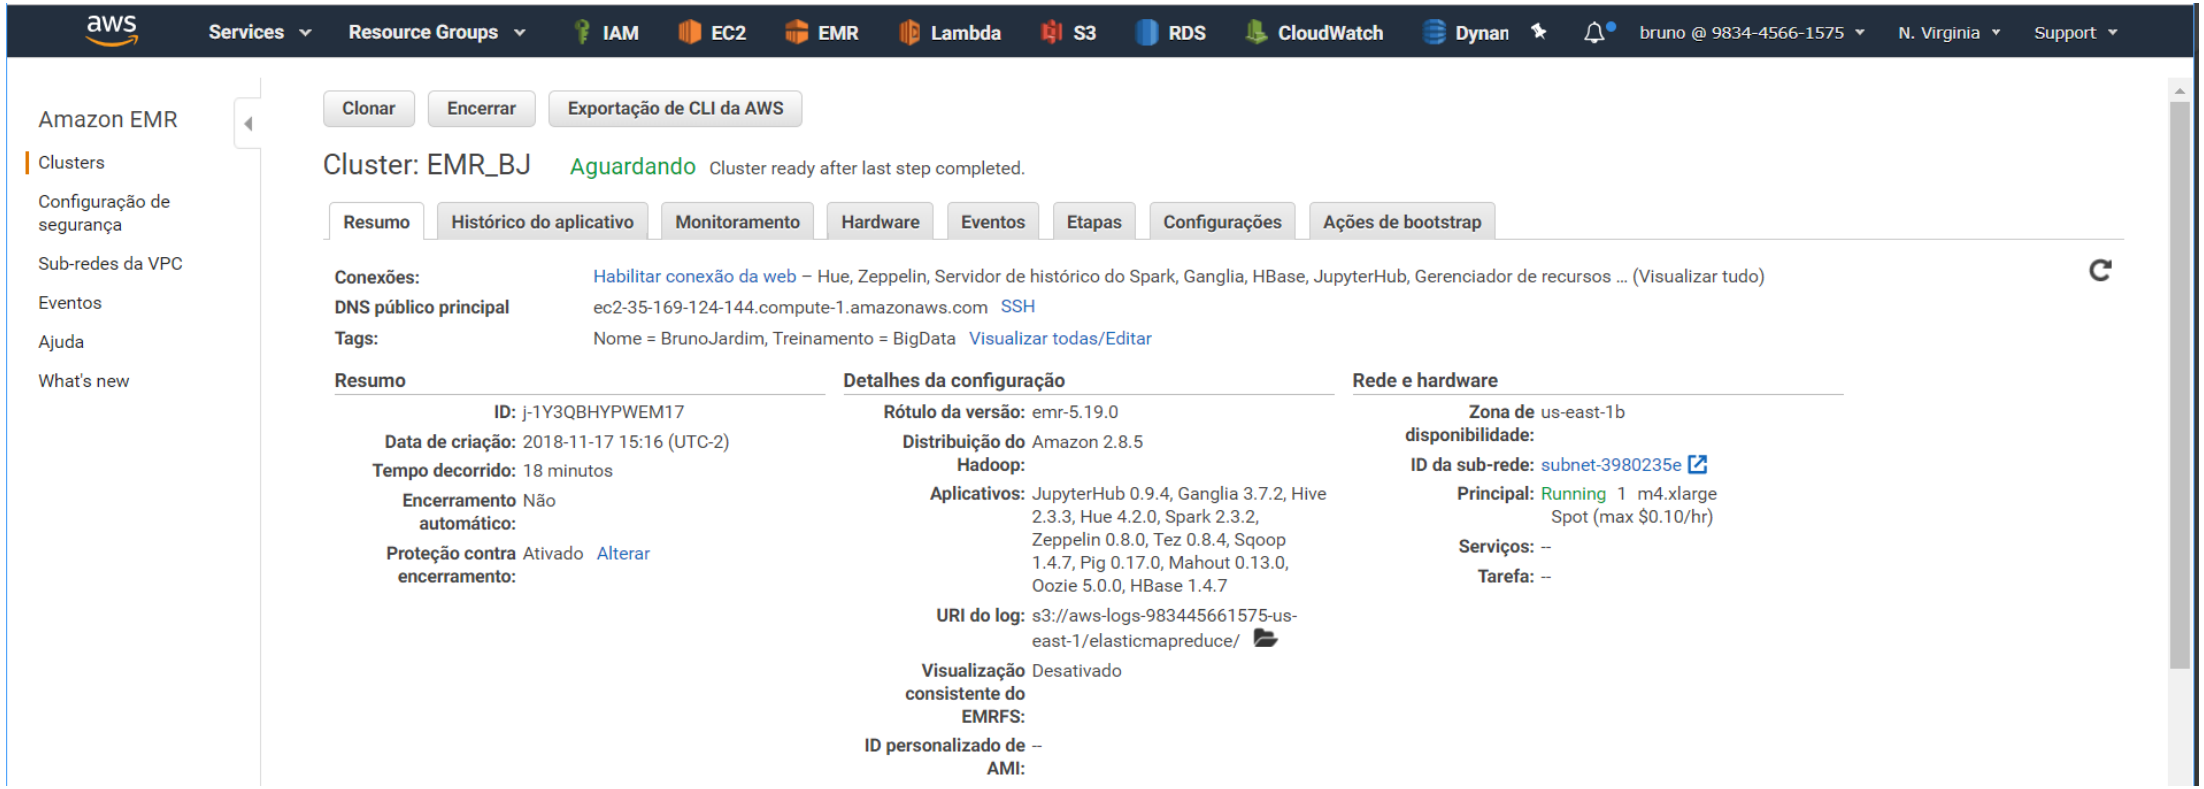
aws
Services
Resource Groups
IAM
EC2
EMR
Lambda
S3
RDS
CloudWatch
Dynan
bruno @ 9834-4566-1575
N. Virginia
Support
Amazon EMR
Clusters
Configuração de segurança
Sub-redes da VPC
Eventos
Ajuda
What's new
Clonar
Encerrar
Exportação de CLI da AWS
Cluster: EMR_BJ
Aguardando
Cluster ready after last step completed.
Resumo
Histórico do aplicativo
Monitoramento
Hardware
Eventos
Etapas
Configurações
Ações de bootstrap
Conexões:
Habilitar conexão da web – Hue, Zeppelin, Servidor de histórico do Spark, Ganglia, HBase, JupyterHub, Gerenciador de recursos ... (Visualizar tudo)
DNS público principal
ec2-35-169-124-144.compute-1.amazonaws.com SSH
Tags:
Nome = BrunoJardim, Treinamento = BigData Visualizar todas/Editar
Resumo
ID: j-1Y3QBHYPWEM17
Data de criação: 2018-11-17 15:16 (UTC-2)
Tempo decorrido: 18 minutos
Encerramento automático: Não
Proteção contra encerramento: Ativado Alterar
Detalhes da configuração
Rótulo da versão: emr-5.19.0
Distribuição do Hadoop: Amazon 2.8.5
Aplicativos: JupyterHub 0.9.4, Ganglia 3.7.2, Hive 2.3.3, Hue 4.2.0, Spark 2.3.2, Zeppelin 0.8.0, Tez 0.8.4, Sqoop 1.4.7, Pig 0.17.0, Mahout 0.13.0, Oozie 5.0.0, HBase 1.4.7
URI do log: s3://aws-logs-983445661575-us-east-1/elasticmapreduce/
Visualização consistente do EMRFS: Desativado
ID personalizado de AMI: --
Rede e hardware
Zona de disponibilidade: us-east-1b
ID da sub-rede: subnet-3980235e
Principal: Running 1 m4.xlarge Spot (max $0.10/hr)
Serviços: --
Tarefa: --

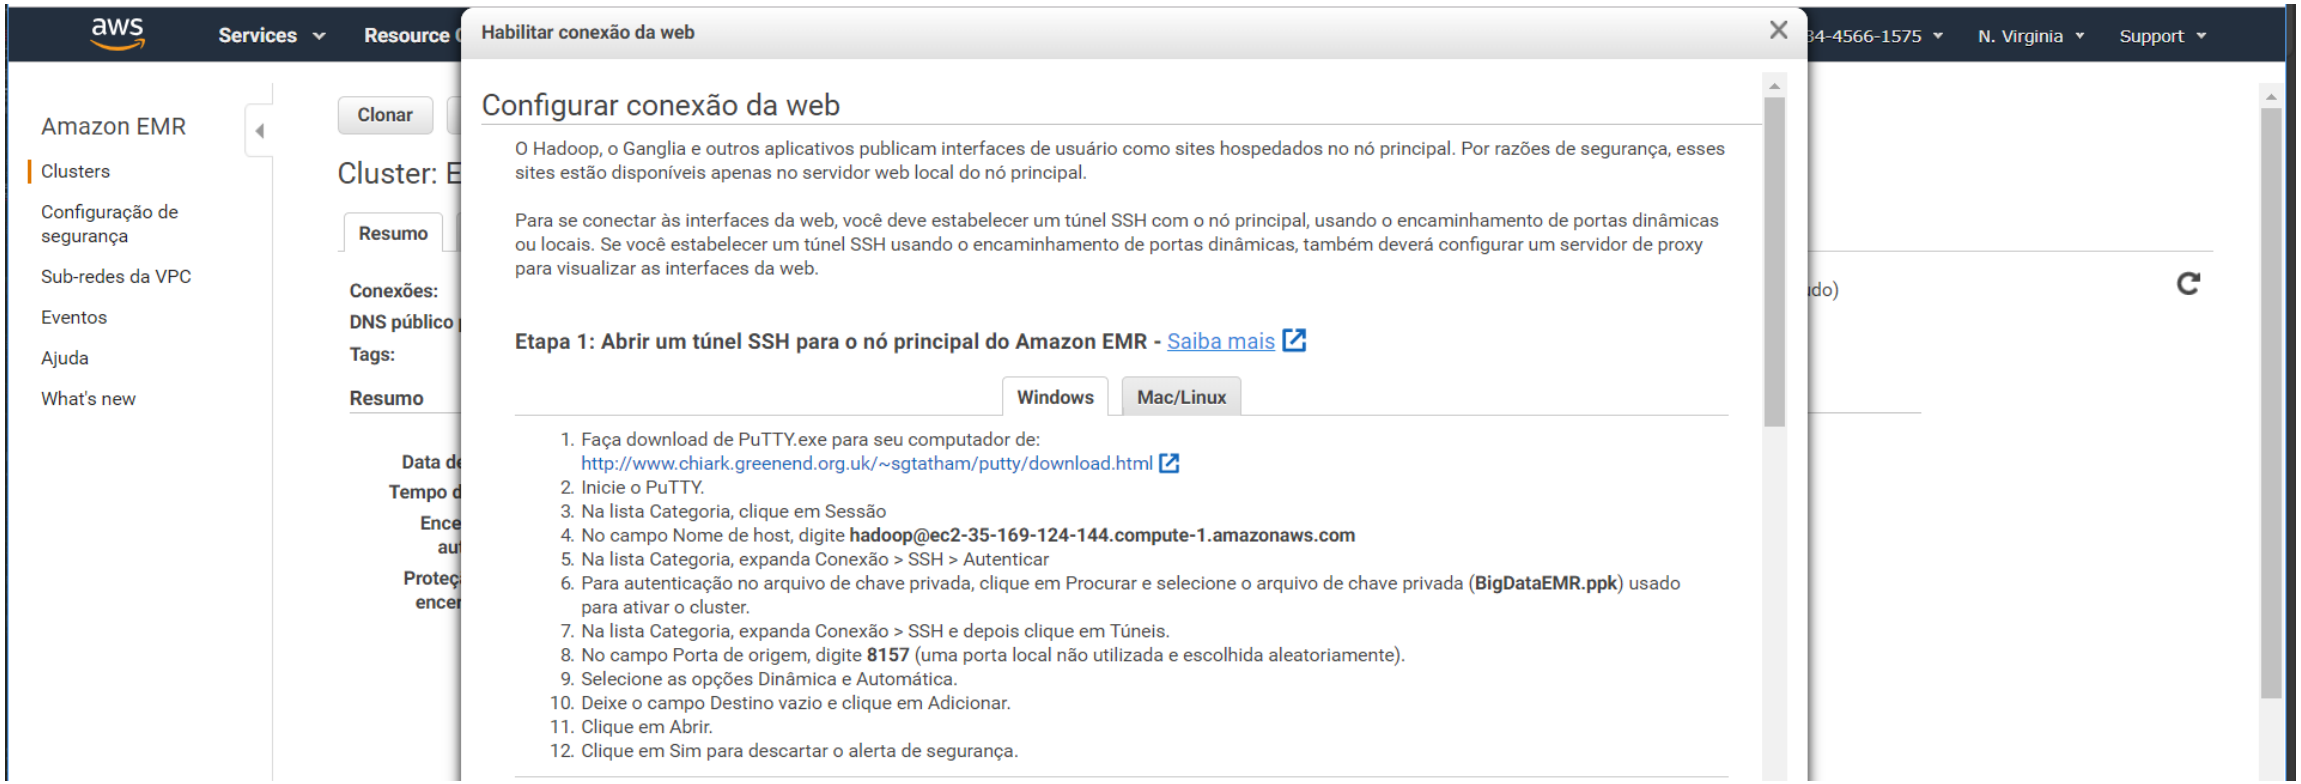
aws
Services
Resource
Habilitar conexão da web
4-4566-1575
N. Virginia
Support
Amazon EMR
Clusters
Configuração de segurança
Sub-redes da VPC
Eventos
Ajuda
What's new
Clonar
Cluster: E
Resumo
Conexões:
DNS público
Tags:
Resumo
Data de
Tempo d
Ence
au
Proteç
encer
Configurar conexão da web
O Hadoop, o Ganglia e outros aplicativos publicam interfaces de usuário como sites hospedados no nó principal. Por razões de segurança, esses sites estão disponíveis apenas no servidor web local do nó principal.
Para se conectar às interfaces da web, você deve estabelecer um túnel SSH com o nó principal, usando o encaminhamento de portas dinâmicas ou locais. Se você estabelecer um túnel SSH usando o encaminhamento de portas dinâmicas, também deverá configurar um servidor de proxy para visualizar as interfaces da web.
Etapa 1: Abrir um túnel SSH para o nó principal do Amazon EMR - Saiba mais
Windows
Mac/Linux
1. Faça download de PuTTY.exe para seu computador de: http://www.chiark.greenend.org.uk/~sgtatham/putty/download.html
2. Inicie o PuTTY.
3. Na lista Categoria, clique em Sessão
4. No campo Nome de host, digite hadoop@ec2-35-169-124-144.compute-1.amazonaws.com
5. Na lista Categoria, expanda Conexão > SSH > Autenticar
6. Para autenticação no arquivo de chave privada, clique em Procurar e selecione o arquivo de chave privada (BigDataEMR.ppk) usado para ativar o cluster.
7. Na lista Categoria, expanda Conexão > SSH e depois clique em Túneis.
8. No campo Porta de origem, digite 8157 (uma porta local não utilizada e escolhida aleatoriamente).
9. Selecione as opções Dinâmica e Automática.
10. Deixe o campo Destino vazio e clique em Adicionar.
11. Clique em Abrir.
12. Clique em Sim para descartar o alerta de segurança.

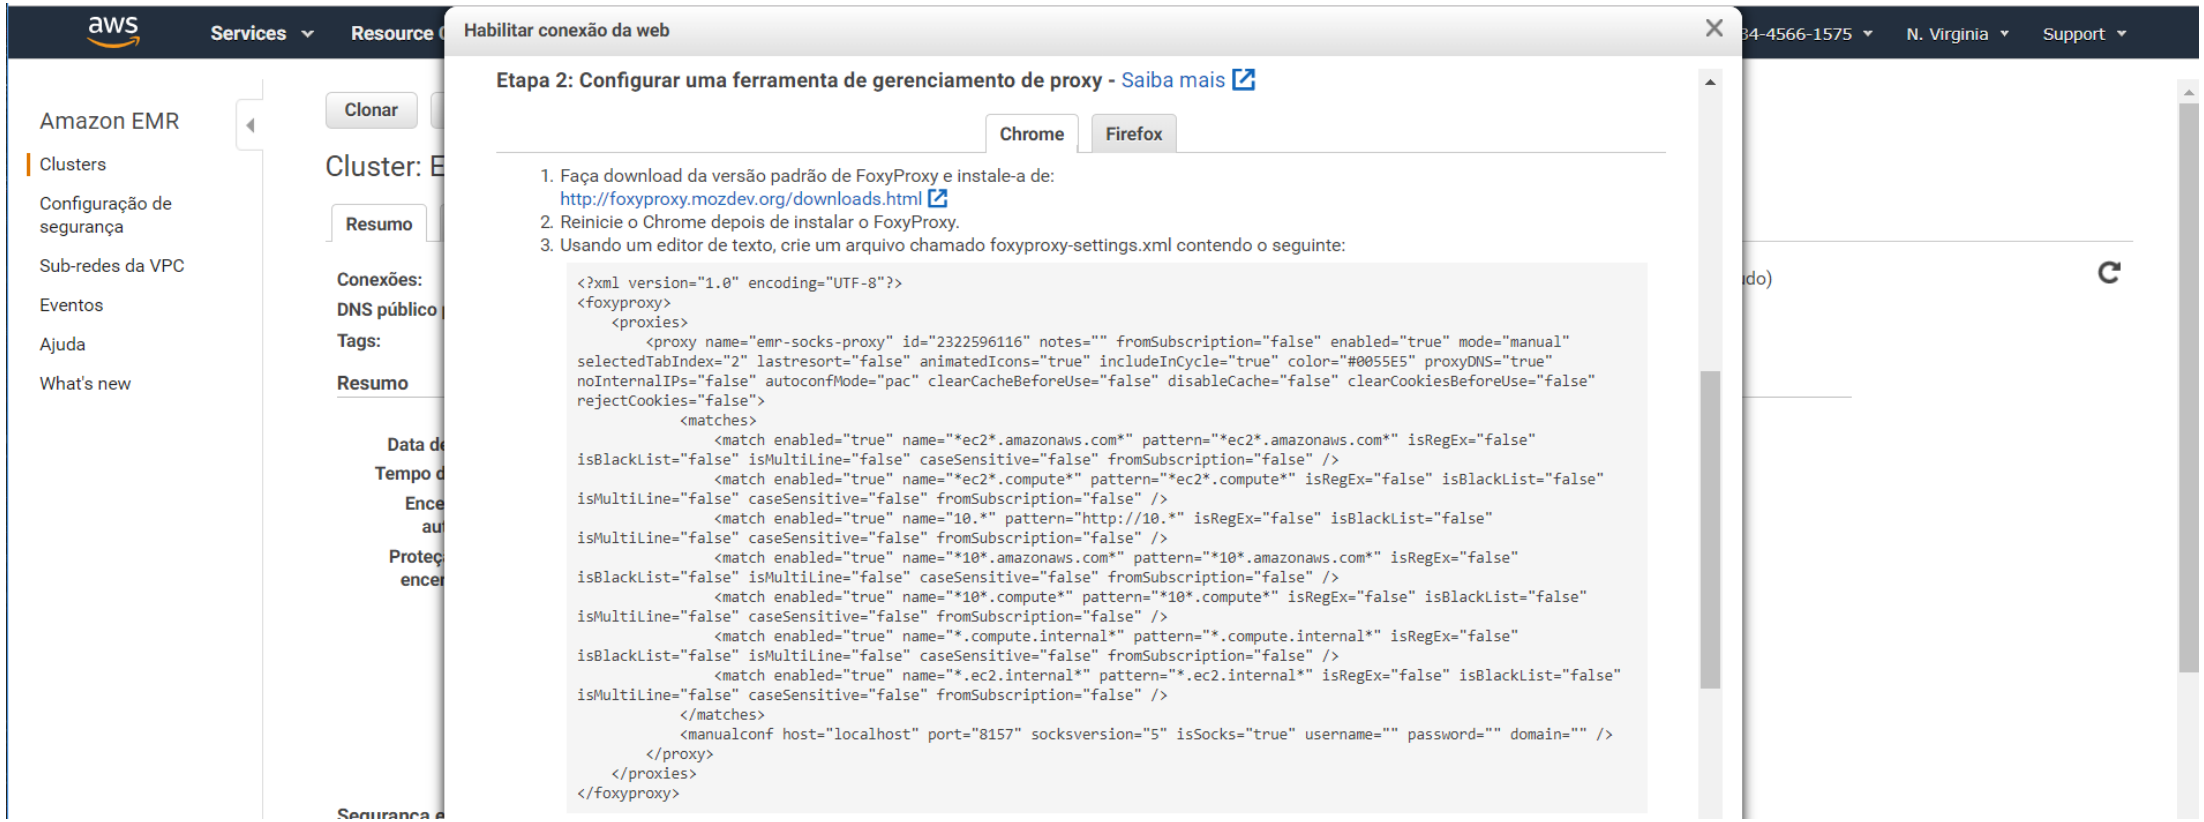
aws
Services
Resource
N. Virginia
Support
Amazon EMR
Clusters
Configuração de segurança
Sub-redes da VPC
Eventos
Ajuda
What's new
Clonar
Cluster: E
Resumo
Conexões:
DNS público
Tags:
Resumo
Habilitar conexão da web
Etapa 2: Configurar uma ferramenta de gerenciamento de proxy - Saiba mais
Chrome
Firefox
1. Faça download da versão padrão de FoxyProxy e instale-a de:
http://foxyproxy.mozdev.org/downloads.html
2. Reinicie o Chrome depois de instalar o FoxyProxy.
3. Usando um editor de texto, crie um arquivo chamado foxyproxy-settings.xml contendo o seguinte:
<?xml version="1.0" encoding="UTF-8"?>
<foxyproxy>
<proxies>
<proxy name="emr-socks-proxy" id="2322596116" notes="" fromSubscription="false" enabled="true" mode="manual" selectedTabIndex="2" lastresort="false" animatedIcons="true" includeInCycle="true" color="#0055E5" proxyDNS="true" noInternalIPs="false" autoconfMode="pac" clearCacheBeforeUse="false" disableCache="false" clearCookiesBeforeUse="false" rejectCookies="false">
<matches>
<match enabled="true" name="*ec2*.amazonaws.com*" pattern="*ec2*.amazonaws.com*" isRegEx="false" isBlackList="false" isMultiLine="false" caseSensitive="false" fromSubscription="false" />
<match enabled="true" name="*ec2*.compute*" pattern="*ec2*.compute*" isRegEx="false" isBlackList="false" isMultiLine="false" caseSensitive="false" fromSubscription="false" />
<match enabled="true" name="10.*" pattern="http://10.*" isRegEx="false" isBlackList="false" isMultiLine="false" caseSensitive="false" fromSubscription="false" />
<match enabled="true" name="*10*.amazonaws.com*" pattern="*10*.amazonaws.com*" isRegEx="false" isBlackList="false" isMultiLine="false" caseSensitive="false" fromSubscription="false" />
<match enabled="true" name="*10*.compute*" pattern="*10*.compute*" isRegEx="false" isBlackList="false" isMultiLine="false" caseSensitive="false" fromSubscription="false" />
<match enabled="true" name="*.compute.internal*" pattern="*.compute.internal*" isRegEx="false" isBlackList="false" isMultiLine="false" caseSensitive="false" fromSubscription="false" />
<match enabled="true" name="*.ec2.internal*" pattern="*.ec2.internal*" isRegEx="false" isBlackList="false" isMultiLine="false" caseSensitive="false" fromSubscription="false" />
</matches>
<manualconf host="localhost" port="8157" socksversion="5" isSocks="true" username="" password="" domain="" />
</proxy>
</proxies>
</foxyproxy>
Segurança e

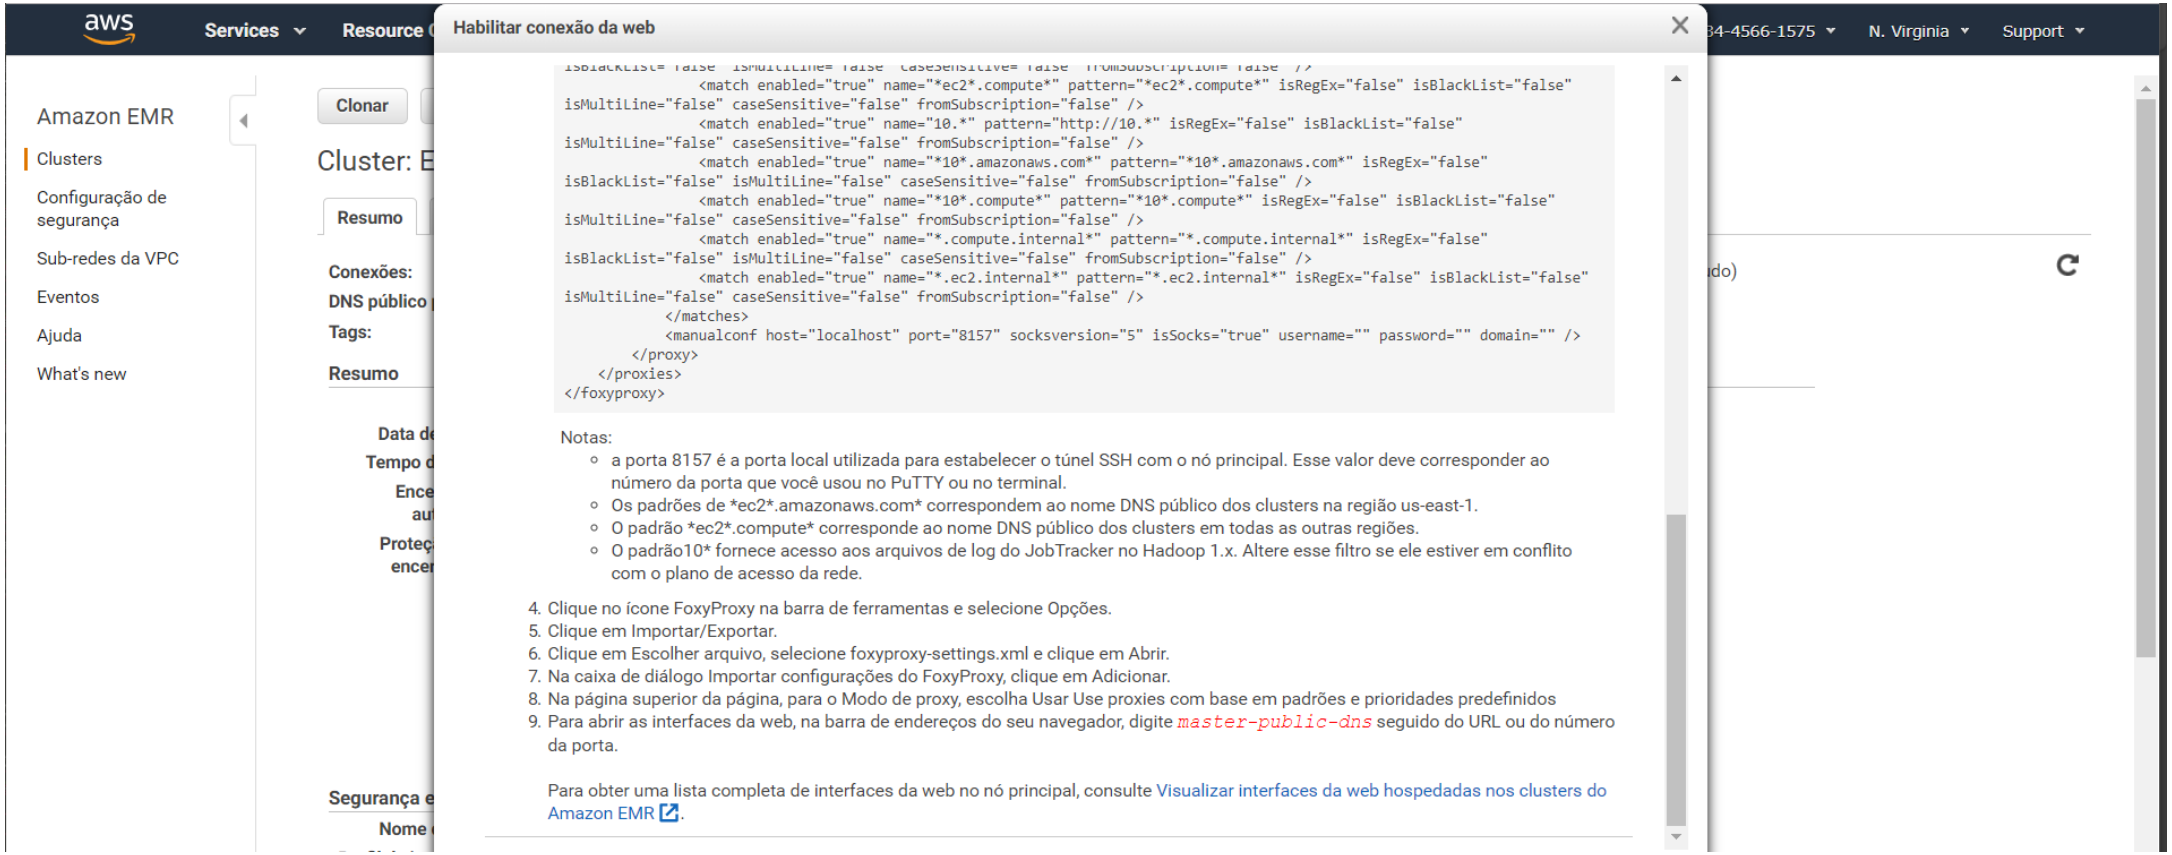
aws
Services
Resource
Habilitar conexão da web
N. Virginia
Support
Amazon EMR
Clusters
Configuração de segurança
Sub-redes da VPC
Eventos
Ajuda
What's new
Clonar
Cluster: E
Resumo
Conexões:
DNS público
Tags:
Resumo
Segurança e
Nome
<match enabled="true" name="*ec2*.compute*" pattern="*ec2*.compute*" isRegEx="false" isBlackList="false" isMultiLine="false" caseSensitive="false" fromSubscription="false" />
<match enabled="true" name="10.*" pattern="http://10.*" isRegEx="false" isBlackList="false" isMultiLine="false" caseSensitive="false" fromSubscription="false" />
<match enabled="true" name="*10*.amazonaws.com*" pattern="*10*.amazonaws.com*" isRegEx="false" isBlackList="false" isMultiLine="false" caseSensitive="false" fromSubscription="false" />
<match enabled="true" name="*10*.compute*" pattern="*10*.compute*" isRegEx="false" isBlackList="false" isMultiLine="false" caseSensitive="false" fromSubscription="false" />
<match enabled="true" name="*.compute.internal*" pattern="*.compute.internal*" isRegEx="false" isBlackList="false" isMultiLine="false" caseSensitive="false" fromSubscription="false" />
<match enabled="true" name="*.ec2.internal*" pattern="*.ec2.internal*" isRegEx="false" isBlackList="false" isMultiLine="false" caseSensitive="false" fromSubscription="false" />
</matches>
<manualconf host="localhost" port="8157" socksversion="5" isSocks="true" username="" password="" domain="" />
</proxy>
</proxies>
</foxyproxy>
Notas:
a porta 8157 é a porta local utilizada para estabelecer o túnel SSH com o nó principal. Esse valor deve corresponder ao número da porta que você usou no PuTTY ou no terminal.
Os padrões de *ec2*.amazonaws.com* correspondem ao nome DNS público dos clusters na região us-east-1.
O padrão *ec2*.compute* corresponde ao nome DNS público dos clusters em todas as outras regiões.
O padrão10* fornece acesso aos arquivos de log do JobTracker no Hadoop 1.x. Altere esse filtro se ele estiver em conflito com o plano de acesso da rede.
4. Clique no ícone FoxyProxy na barra de ferramentas e selecione Opções.
5. Clique em Importar/Exportar.
6. Clique em Escolher arquivo, selecione foxyproxy-settings.xml e clique em Abrir.
7. Na caixa de diálogo Importar configurações do FoxyProxy, clique em Adicionar.
8. Na página superior da página, para o Modo de proxy, escolha Usar Use proxies com base em padrões e prioridades predefinidos
9. Para abrir as interfaces da web, na barra de endereços do seu navegador, digite master-public-dns seguido do URL ou do número da porta.
Para obter uma lista completa de interfaces da web no nó principal, consulte Visualizar interfaces da web hospedadas nos clusters do Amazon EMR.

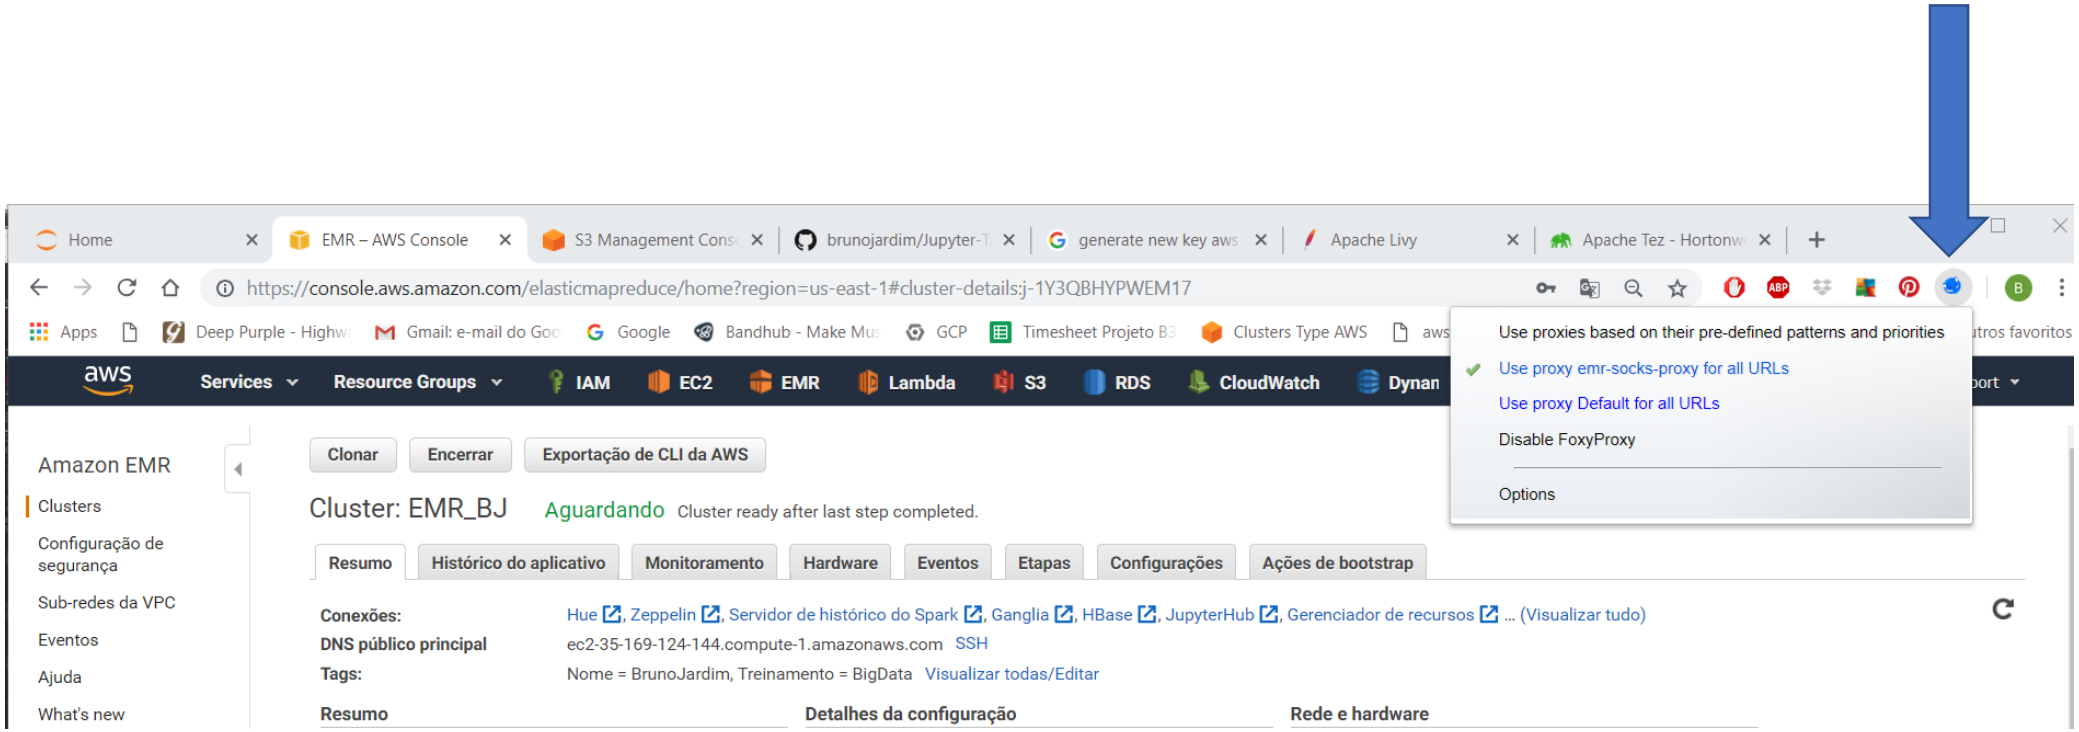
Home
EMR – AWS Console
S3 Management Cons
brunojardim/Jupyter-T
generate new key aws
Apache Livy
Apache Tez - Hortonw
https://console.aws.amazon.com/elasticmapreduce/home?region=us-east-1#cluster-details:j-1Y3QBHYPWEM17
Apps
Deep Purple - Highw
Gmail: e-mail do Goo
Google
Bandhub - Make Mus
GCP
Timesheet Projeto B3
Clusters Type AWS
aws
Use proxies based on their pre-defined patterns and priorities
Use proxy emr-socks-proxy for all URLs
Use proxy Default for all URLs
Disable FoxyProxy
Options
Services
Resource Groups
IAM
EC2
EMR
Lambda
S3
RDS
CloudWatch
Amazon EMR
Clusters
Configuração de segurança
Sub-redes da VPC
Eventos
Ajuda
What's new
Clonar
Encerrar
Exportação de CLI da AWS
Cluster: EMR_BJ
Aguardando
Cluster ready after last step completed.
Resumo
Histórico do aplicativo
Monitoramento
Hardware
Eventos
Etapas
Configurações
Ações de bootstrap
Conexões:
Hue, Zeppelin, Servidor de histórico do Spark, Ganglia, HBase, JupyterHub, Gerenciador de recursos ... (Visualizar tudo)
DNS público principal
ec2-35-169-124-144.compute-1.amazonaws.com SSH
Tags:
Nome = BrunoJardim, Treinamento = BigData Visualizar todas/Editar
Resumo
Detalhes da configuração
Rede e hardware